BRIEF 8 — ASSURRISK

Diagnostic de la qualité des données, risques et RGPD

Objectif : évaluer la qualité et l'exploitabilité des données avant la mise en reporting.

Périmètre : tables dimensionnelles et tables de faits du schéma public.

Source : résultats consignés dans le fichier de travail fourni ; ils n'ont pas été réexécutés indépendamment lors de la rédaction.

1. Synthèse exécutive

La base contient notamment **25 040 assurés**, **32 000 contrats**, **12 490 sinistres** et **13 890 indemnisations**. Plusieurs contrôles de relations n'ont détecté aucun enregistrement orphelin dans les cas testés. Des points restent à investiguer avant validation des indicateurs : incohérences de dates, doublons potentiels de sinistres, données personnelles manquantes ou répétées et normalisation des libellés.

2. Volumes des tables

Table	Nombre de lignes
contrat_garantie	89 600
dim_agence	25
dim_assure	25 040
dim_contrat	32 000
dim_garantie	12
fact_indemnisation	13 890
fact_sinistre	12 490

La conformité aux volumes attendus doit être confirmée par comparaison avec la documentation du brief, dont les valeurs de référence ne figurent pas dans les résultats fournis.

3. Principales anomalies et limites

Contrôle	Résultat rapporté	Risque / interprétation
Doublons potentiels	100 groupes ; 200 lignes ; 100 lignes excédentaires potentielles	À confirmer par règle métier avant suppression.
Dates incohérentes	80 sinistres déclarés avant survenance ; écart max 14 jours	Peut refléter les délais de déclaration ; vérifier les sources.
Contrats non actifs	70 résiliés + 30 expirés = 100 sinistres	Vérifier la couverture à la date de survenance ; le statut actuel ne suffit pas.
Localisations manquantes	40 villes ; 30 départements ; 60 régions ; 60 combinaisons complètes	Problèmes de jointures géographiques ; les catégories peuvent se chevaucher.
Coordonnées invalides	0 latitude hors plage ; 0 longitude hors plage ; 0 couple (0,0)	Aucune anomalie selon ces règles, sans garantie de localisation réelle correcte.
Données personnelles	500 dates de naissance manquantes ; 757 emails manquants ; 24 185 emails distincts, répétitions	Limites de qualité à investiguer.

Relations testées : 8 clés étrangères déclarées ; les contrôles rapportés ont trouvé 0 contrat sans agence, 0 sinistre sans contrat, 0 sinistre sans garantie et 0 indemnisation sans sinistre.

4. Indicateurs métier exploratoires

Sinistres par année : 6 490 en 2024 et 6 000 en 2025, soit –490 (environ –7,55 %). La période 2025 est incomplète dans les données observées (survenance jusqu'au 28 octobre 2025) : cette baisse ne doit pas être interprétée comme une baisse réelle du risque.

Type de sinistre	Nombre	Montant moyen estimé
Dégât des eaux	3 746	4 385,14 €
Vol	2 196	7 452,78 €
Grêle	1 608	3 333,38 €
Tempête	1 546	11 355,55 €
Bris de glace	1 466	13 223,03 €
Responsabilité civile	900	2 600,03 €
Incendie	628	26 732,65 €
Inondation	400	18 111,01 €

L'incendie présente le montant moyen estimé le plus élevé parmi les catégories listées ; les dégâts des eaux sont les plus fréquents. Les montants doivent être rapprochés des volumes et des montants totaux avant interprétation.

Autres résultats rapportés : Occitanie : 1 870 sinistres ; 60 sinistres sans région. Statuts : clôturé 4 850, en cours 2 460, expertisé 2 400, refusé 1 800, déclaré 980. Montant total des indemnisations : 57 602 664,10 € ; montant moyen : 4 147,06 €.

5. RGPD et minimisation

La table dim_assure contient des données directement identifiantes (nom, prénom, email), la date de naissance et des informations géographiques. L'identifiant assure_id permet de relier les informations d'une même personne et ne garantit donc pas à lui seul l'anonymat.

- Ne pas exposer les noms, prénoms et emails dans les tableaux de bord généraux.
- Privilégier les indicateurs agrégés et limiter l'accès selon le besoin métier.
- Normaliser les emails avec LOWER(TRIM(email)) pour les contrôles, puis investiguer les répétitions.
- Ne pas inventer de valeurs pour remplacer les données manquantes.
- Documenter les colonnes nécessaires au reporting et les limites des indicateurs.

6. Investigations prioritaires

- Identifier l'origine des 500 dates de naissance manquantes.
- Confirmer si les 757 emails manquants sont acceptables au regard des besoins métier.
- Vérifier les emails partagés ou répétés ; cela ne prouve pas un doublon de personne.
- Examiner les 80 incohérences de dates et les règles de saisie.
- Confirmer les 100 groupes de doublons potentiels avec les identifiants et les attributs complémentaires.
- Vérifier la couverture des 100 sinistres associés à des contrats actuellement non actifs.
- Compléter les localisations uniquement à partir de sources fiables.
- Valider les règles de standardisation des types de sinistres.

7. Traitements avant reporting

- Créer des vues ne contenant que les colonnes nécessaires.
- Standardiser les libellés avec des règles documentées et validées.
- Automatiser les contrôles de dates, valeurs manquantes et doublons potentiels.
- Ne pas modifier les données sources avant investigation et validation.
- Afficher la période couverte et la date de mise à jour des tableaux de bord.

8. Conclusion

La base permet déjà plusieurs analyses descriptives et les contrôles de relations rapportés sont satisfaisants pour les cas testés. La mise en reporting doit être précédée d’une investigation des dates incohérentes, doublons potentiels, contrats non actifs, données manquantes et emails répétés. La minimisation des données personnelles doit être appliquée dès la préparation des vues.

Limite importante : les résultats proviennent des commentaires consignés dans le fichier de travail et doivent être vérifiés dans PostgreSQL avant validation définitive, en particulier les volumes de référence et les montants financiers.